

SEGMENTASI PEMBANGUNAN INFRASTRUKTUR TRANSPORTASI DARAT ANTAR PROVINSI DI INDONESIA MENGGUNAKAN *K-MEANS* DAN PCA

Lila Fifa Ardani ^{1*}, Desi Nofitasari ², Irma Liza ³, Muhammad Nasrudin ⁴, Shindi Shella May Wara ⁵

^{1,2,3,4,5} Universitas Pembangunan Nasional Veteran Jawa Timur

***e-mail** corresponding author: desinofitasari123.jbg@gmail.com

Abstract

Land transportation infrastructure development in Indonesia still faces significant disparities across provinces, necessitating a data-driven analytical approach to support more targeted policy formulation. This study aims to segment 38 provinces in Indonesia based on 15 road infrastructure indicators using Principal Component Analysis (PCA) and K-Means Clustering. Data were sourced from the Land Transportation Statistics 2024 published by the Central Statistics Agency (BPS). Data Preprocessing included handling 34 Missing Values through median imputation and Z-score standardization. Assumption tests yielded a KMO value of 0.6155 and a Bartlett's test p-value of 0.00, indicating that the data are suitable for further analysis. PCA reduced the 15 variables into five principal components based on the Kaiser criterion. Determination of the optimal number of clusters using the Elbow method and Silhouette Score produced $k=4$ with the highest Silhouette Score of 0.3660. The clustering results revealed four province clusters with distinct characteristics, namely a cluster dominated by road damage and unpaved surfaces, a cluster reflecting general infrastructure conditions, a cluster with relatively neutral characteristics, and a cluster representing the most developed infrastructure conditions comprising West Java, Central Java, and East Java. These findings are expected to serve as an empirical basis for formulating differentiated infrastructure development policies in accordance with the characteristics of each region.

Keywords: *K-Means Clustering, Principal Component Analysis, Road Infrastructure, Province Segmentation, Indonesia*

1. PENDAHULUAN

Pembangunan infrastruktur transportasi darat merupakan salah satu pilar utama dalam mendukung pertumbuhan ekonomi nasional, pemerataan pembangunan wilayah, serta peningkatan konektivitas antarprovinsi di Indonesia. Infrastruktur yang memadai tidak hanya memperlancar mobilitas barang dan jasa, tetapi juga berperan penting dalam meningkatkan akses masyarakat terhadap layanan pendidikan, kesehatan, serta aktivitas ekonomi produktif [1]. Namun demikian, hingga saat ini pembangunan infrastruktur transportasi darat di Indonesia masih menghadapi tantangan serius berupa ketimpangan antarwilayah yang menyebabkan perbedaan tingkat perkembangan dan aksesibilitas antarprovinsi [2].

Ketimpangan pembangunan infrastruktur tersebut terlihat jelas pada kualitas dan kuantitas jalan di berbagai daerah. Pemerintah mencatat bahwa terdapat perbedaan signifikan antara jalan nasional, provinsi, dan kabupaten/kota. Jalan nasional memiliki tingkat kuantitas lebih dari 90%, sedangkan jalan provinsi berada pada kisaran 70%, dan jalan kabupaten/kota hanya sekitar 50% dalam kondisi baik [3]. Kondisi ini

menunjukkan masih adanya disparitas kualitas infrastruktur yang cukup besar antarwilayah administrasi di Indonesia, sehingga diperlukan pendekatan analitis berbasis data untuk mengidentifikasi karakteristik setiap wilayah sebagai dasar perumusan kebijakan yang lebih tepat sasaran[4].

Seiring dengan perkembangan teknologi analisis data, metode data mining banyak digunakan untuk mengelompokkan wilayah berdasarkan kesamaan karakteristik. Salah satu metode yang paling umum digunakan adalah *K-Means Clustering*, yaitu metode *unsupervised learning* yang mengelompokkan data berdasarkan kedekatan jarak antar objek dalam suatu ruang fitur. Metode ini banyak digunakan dalam berbagai penelitian karena sederhana, efisien, dan mampu menghasilkan kelompok yang mudah diinterpretasikan, termasuk dalam analisis sosial ekonomi dan pembangunan wilayah [5].

Namun, data indikator pembangunan umumnya memiliki banyak variabel yang saling berkorelasi, sehingga dapat menyebabkan penurunan kualitas *clustering* jika digunakan secara langsung. Oleh karena itu, diperlukan metode reduksi dimensi seperti *Principal Component Analysis* (PCA) untuk menyederhanakan data tanpa kehilangan informasi penting. PCA berfungsi untuk mengubah variabel awal menjadi beberapa komponen utama yang mampu merepresentasikan variasi data secara optimal dan mengurangi multikolinearitas antar variabel[6].

Penelitian terdahulu menunjukkan bahwa kombinasi PCA dan *K-Means Clustering* mampu menghasilkan pengelompokan data yang lebih stabil dan representatif. Salah satu penelitian oleh Hutagalung dan Nuramaliyah tahun 2026 menunjukkan bahwa penerapan PCA pada indikator infrastruktur dan layanan dasar sebelum proses *clustering* dengan *K-Means* mampu meningkatkan kualitas pengelompokan wilayah. Hasil penelitian tersebut menunjukkan bahwa pendekatan ini lebih mampu menggambarkan karakteristik antarwilayah secara jelas [7].

Selain itu, berbagai penelitian lain juga menunjukkan bahwa integrasi PCA dan *K-Means* efektif digunakan dalam berbagai kasus analisis data di Indonesia, seperti pengelompokan data kemiskinan, ketenagakerjaan, pembangunan wilayah, dan indikator sosial ekonomi. Pendekatan ini terbukti mampu meningkatkan kualitas *clustering* untuk menghasilkan segmentasi wilayah yang lebih akurat dan mudah diinterpretasikan dalam perumusan kebijakan publik[8][9].

Berdasarkan permasalahan ketimpangan infrastruktur serta keberhasilan PCA dan *K-Means* pada penelitian sebelumnya, khususnya Hutagalung dan Nuramaliyah (2026) [10], penelitian ini mengacu pada studi tersebut dengan cakupan wilayah yang lebih luas, yaitu tingkat provinsi di Indonesia dengan fokus pada indikator pembangunan infrastruktur transportasi darat. Oleh karena itu, penelitian ini bertujuan untuk melakukan segmentasi provinsi di Indonesia menggunakan metode *Principal Component Analysis* (PCA) dan *K-Means Clustering*, dengan harapan dapat memberikan gambaran pengelompokan wilayah berdasarkan tingkat pembangunan infrastruktur sebagai dasar perumusan kebijakan yang lebih merata, efektif, dan berbasis data.

2. TINJAUAN PUSTAKA

2.1 Preprocessing

Preprocessing adalah tahapan sebelum melakukan proses analisis lanjutan yang bertujuan untuk meningkatkan kualitas data. Tahapan nya mencakup memeriksa *Missing Value* dan menangani *Missing Value* (nilai kosong) menggunakan mean, median, atau modus dan bisa juga dilakukan penghapusan nilai kosong, keputusan tersebut diambil sesuai dengan kebutuhan [11]. Pada *data cleaning* juga melihat kesalahan pencatatan tipe data yang dapat mempengaruhi analisis.

2.2 Standarisasi

Standarisasi merupakan tahap *Preprocessing* data untuk menyamakan skala antarvariabel agar kontribusinya seimbang dalam analisis. Digunakan metode *Z-score* yang menstandarkan data menjadi rata-rata nol dan simpangan baku satu, sehingga seluruh variabel berada pada skala yang sama dan mendukung proses reduksi dimensi dan klusterisasi [13]. Transformasi *Z-score* dirumuskan sebagai berikut:

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

Keterangan :

- z : Nilai hasil standarisasi (*Z-score*)
- x : Nilai observasi
- μ : Rata-rata variabel
- σ : Simpangan baku (standar deviasi) variabel

2.3 KMO (Kaiser-Meyer-Olkin)

Kaiser-Meyer-Olkin (KMO) adalah ukuran yang digunakan untuk menguji kecukupan sampel sebelum dilakukan *Principal Component Analysis* (PCA) dan analisis kluster. Nilai KMO menunjukkan tingkat kecukupan korelasi antar variabel, di mana data dianggap layak untuk dianalisis apabila nilai KMO lebih besar dari 0,5. Berikut rumus yang digunakan[14].

$$KMO = \frac{\sum r_{ij}^2}{\sum r_{ij}^2 + \sum p_{ij}^2} \quad (2)$$

Keterangan :

- r_{ij}^2 : Koefisien korelasi
- p_{ij}^2 : Koefisien korelasi parsial

2.4 Uji Bartlett

Uji *Bartlett* adalah salah satu uji asumsi statistik untuk mengetahui korelasi antara data untuk memenuhi asumsi dalam multivariat. Untuk menghitung uji *Bartlett* dapat menggunakan rumus[15].

$$X^2 = -\left(n - 1 - \frac{(2p + 5)}{6}\right) \ln |R| \quad (3)$$

Keterangan :

n : Jumlah sampel

p : Jumlah variabel

$|R|$: Determinan dari matriks korelasi

Uji *Bartlett* akan signifikan jika p-valuenya < 0.05 menunjukkan terdapat hubungan antar variabel, nilai signifikan yang kecil mengindikasikan matriks korelasi bukan matriks identitas sehingga variabel dalam data memiliki keterkaitan yang cukup untuk proses analisis lanjutan[16].

2.5 Analisis Korelasi

Analisis korelasi digunakan untuk mengukur tingkat hubungan antarvariabel dalam suatu dataset. Koefisien *korelasi pearson* memiliki nilai antara -1 hingga $+1$, di mana nilai positif menunjukkan hubungan searah, nilai negatif menunjukkan hubungan berlawanan arah, dan nilai mendekati 0 menunjukkan hubungan yang lemah. [17]. Secara matematis, koefisien korelasi dirumuskan sebagai:

$$r_{ij} = \frac{Cov(X_i, X_j)}{\sigma_i \times \sigma_j} \quad (4)$$

Keterangan :

r_{ij} : Koefisien korelasi

$Cov(X_i, X_j)$: Kovarians antar variabel

σ_i : Simpangan baku variabel X_i

σ_j : Simpangan baku variabel X_j

2.6 PCA (*Principal Component Analysis*)

Principal Component Analysis (PCA) merupakan metode reduksi dimensi yang mengubah sekumpulan variabel yang berkorelasi menjadi beberapa komponen utama yang tidak berkorelasi. Komponen utama dibentuk berdasarkan nilai eigen (*eigenvalue*) dan vektor eigen (*eigenvector*) dari matriks kovarians, dengan komponen yang dipertahankan umumnya memiliki nilai eigen (λ) lebih besar dari satu. Berikut persamaan PCA[18].

$$Y = X.W \quad (5)$$

Dengan Y sebagai hasil transformasi PCA, X adalah data setelah standarisasi serta sebagai matriks *eigenvector* yang terpilih. Nilai *eigenvalue* didapatkan dari rumus berikut[19]:

$$|\lambda I - A| = 0 \quad (6)$$

Dengan λ adalah koefisien *eigen*, I untuk matriks identitas dan A untuk matrik data. Kemudian untuk menghitung *eigenvector* diperoleh dari persamaan berikut dengan X adalah *eigenvector*.

$$(\lambda I - A)X = 0 \quad (7)$$

2.7 Loading PCA dan Pembentukan

Loading pada *Principal Component Analysis* (PCA) merupakan nilai yang menunjukkan kontribusi atau keterkaitan antara variabel asli terhadap komponen utama yang terbentuk. Semakin besar nilai *loading* akan semakin besar juga pengaruh variabel dalam membentuk PCA. *Loading* PCA dapat dihitung melalui rumus [20] :

$$L_{ij} = e_{ij} \sqrt{\lambda_j} \quad (8)$$

Keterangan :

L_{ij} : *Loading* variabel ke-I pada komponen ke-j

e_{ij} : Elemen *eigenvector*

λ_j : *Eigenvalue* komponen ke-j

Nilai *loading* diperoleh dari hasil perkalian antara *eigenvector* dengan akar dari *eigenvalue*. *Eigenvector* menunjukkan arah dari komponen utama sehingga kombinasi keduanya mencerminkan kontribusi yang relatif setiap variabel terhadap pembentukan komponen utama.

2.8 Elbow Method

Metode *Elbow* digunakan untuk menentukan jumlah kluster optimal pada algoritma *K-Means* dengan mengevaluasi nilai *Within Cluster Sum of Squares* (WCSS) atau inerti pada berbagai jumlah kluster [21]. Nilai WCSS menunjukkan tingkat kedekatan data terhadap *centroid* klasternya, di mana semakin kecil nilai WCSS maka semakin homogen anggota dalam kluster. Jumlah kluster optimal ditentukan berdasarkan titik siku (*Elbow point*) pada grafik hubungan antara jumlah kluster dan nilai WCSS, serta dapat didukung oleh evaluasi menggunakan *Silhouette Score*.

$$WCSS = \sum_{i=1}^k \sum_{x \in C_i} |x - \mu_i|^2 \quad (9)$$

Keterangan :

$WCSS$: *Within Cluster Sum Of Squares*

k : Jumlah kluster

x : Data anggota kluster

μ_i : *Centroid* kluster ke- i

2.9 K-Means

K-Means merupakan metode *clustering non hierarki* yang membagi data jadi beberapa kelompok berdasarkan tingkat kemiripan karakteristik datanya [21]. Pada *K-*

Means membutuhkan penentuan jumlah *cluster* hingga ditemukan jarak terpendek antara *cluster*, menggunakan rumus berikut.

$$d(z_p, M_j) = \sqrt{\sum_{k=1}^d (z_{p,k} - M_{j,k})^2} \quad (10)$$

Hitung *cluster centroid* menggunakan persamaan berikut:

$$M_j = \frac{1}{n_j} \left(\sum z_p \right) \quad (11)$$

Keterangan:

- z_p : Data atau objek ke- p
- M_j : *Centroid* atau pusat center
- K : Indeks atribut atau variable
- D : Jumlah atribut atau dimensi data
- $d(z_p, M_j)$: Jarak anatara data dan *centroid*
- n_j : Jumlah data yang menjadi anggota kluster ke j

2.10 *Sillhouette Score*

Sillhouette Score adalah teknik yang menggambarkan seberapa dekat antara object dan kluster. *Sillhouette* ini menunjukkan seberapa idealnya jumlah kluster yang terbentuk, jika rata-ratanya besar menunjukkan bahwa terdapat jumlah kluster yang ideal atau bisa disebut bagus[22]. Berikut rumus mencari *Sillhouette* [23]:

$$S(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (12)$$

Keterangan :

- $S(i)$: *Sillhouette score* data ke- i .
- $a(i)$: Rata-rata jarak data i dengan *cluster* sendiri.
- $b(i)$: Rata-rata jarak data i dengan *cluster* terdekat lainnya.

Nilai yang akan dihasilkan *sillhouette* terdapat pada kisaran -1 hingga 1, dimana ketika nilainya mendekati 1 maka akan semakin baik. Jika nilainya mendekati -1 maka akan semakin buruk pengelompokkan datanya.

3. METODE PENELITIAN

3.1 Sumber Data

Penelitian ini menggunakan data sekunder yang diperoleh dari publikasi *Statistik Transportasi Darat 2024* yang diterbitkan oleh Badan Pusat Statistik (BPS) [24]. Unit analisis penelitian terdiri atas 38 provinsi di Indonesia. Variabel yang digunakan menggambarkan kondisi infrastruktur jalan berdasarkan tingkat kewenangan, kondisi jalan, dan jenis permukaan jalan.

3.2 Variabel Penelitian


Penelitian ini menggunakan 15 indikator infrastruktur jalan sebagai variabel bebas (X) tanpa ada variabel terikat (Y). Adapun rincian variabel yang digunakan disajikan pada

Tabel 1. Variabel Penelitian

Kode	Nama Variabel	Keterangan
X1	Jalan negara baik	Panjang jalan negara kondisi baik
X2	Jalan negara sedang	Panjang jalan negara kondisi sedang
X3	Jalan negara rusak	Panjang jalan negara kondisi rusak
X4	Jalan negara rusak berat	Panjang jalan negara kondisi rusak berat
X5	Jalan provinsi baik	Panjang jalan provinsi kondisi baik
X6	Jalan provinsi rusak	Panjang jalan provinsi kondisi rusak
X7	Jalan provinsi sedang	Panjang jalan provinsi kondisi sedang
X8	Jalan provinsi rusak berat	Panjang jalan provinsi kondisi rusak berat
X9	Jalan kabupaten atau kota baik	Panjang jalan kabupaten/kota kondisi baik
X10	Jalan kabupaten atau kota sedang	Panjang jalan kabupaten/kota kondisi sedang
X11	Jalan kabupaten atau kota rusak	Panjang jalan kabupaten/kota kondisi rusak
X12	Jalan kabupaten atau kota rusak berat	Panjang jalan kabupaten/kota kondisi rusak berat
X13	Tidak Diaspal Negara	Panjang jalan negara kondisi tidak diaspal
X14	Krikil Provinsi	Panjang jalan provinsi yang masih komponen kerikil
X15	Krikil Kabupaten/Kota	Panjang jalan kabupaten/kota yang masih komponen kerikil

3.3 Diagram Alir

Proses penelitian ini dilakukan melalui tahapan yang saling berkaitan, berikut adalah alur penelitian untuk gambaran tahapan penelitian.



Gambar 1. Diagram Alir

Berdasarkan diagram alir penelitian diawali dengan tahap pengumpulan data dilanjutkan dengan *Preprocessing* data untuk menyiapkan data sebelum analisis. Selanjutnya dilakukan uji asumsi PCA yang meliputi uji KMO, Bartlett, dan korelasi untuk memastikan data layak dianalisis PCA. Jika asumsi belum terpenuhi, dilakukan perbaikan pada data dan pengujian kembali. Jika asumsi terpenuhi, analisis dilanjutkan reduksi dimensi menggunakan PCA. Hasil PCA kemudian digunakan dalam proses *clustering* menggunakan metode *K-Means* untuk mengelompokkan provinsi berdasarkan karakteristik. Tahap akhir interpretasi hasil *cluster* untuk kesimpulan penelitian.

4. HASIL DAN PEMBAHASAN

4.1 Data Cleaning

Tahapan praproses data dilakukan untuk menjaga kualitas data sebelum analisis. Ditemukan 34 *Missing Value* pada beberapa variabel infrastruktur jalan. Ringkasan *Missing Value* disajikan pada tabel berikut.

Tabel 2. Ringkasan Penanganan *Missing Value*

<i>Missing Value</i>	Jumlah
Sebelum imputasi	34
Setelah imputasi median	0

Berdasarkan tabel 2, *Missing Value* ditangani dengan imputasi median karena lebih tahan terhadap outlier. Setelah proses ini, tidak ada lagi *Missing Value* maupun data duplikat, data siap digunakan.


4.2 Uji Asumsi

Sebelum analisis lanjutan, dilakukan uji asumsi (KMO, *Bartlett*, dan korelasi) untuk memastikan kelayakan data.

Tabel 3. Hasil Uji KMO dan Uji *Bartlett*

Uji Asumsi	Statistika uji	Nilai	Interpretasi
<i>Kaiser Meyer Olkin</i> (KMO)	KMO	0,6155	Memenuhi syarat
<i>Bartlett's</i>	p-value	0,00	Signifikan

Dari tabel diatas dapat dilihat bahwa hasil nilai KMO adalah 0,6155 menunjukkan data masuk kategori cukup memadai untuk dilakukan analisis lanjutan karena sudah memenuhi syarat KMO yang bernilai $KMO > 0,5$. Sedangkan Uji *Bartlett's* memiliki nilai p-value 0,00 yang artinya $<0,05$ sehingga terdapat korelasi yang signifikan antara variabel. Uji selanjutnya adalah korelasi mellaui heatmap.

**Gambar 2.** Heatmap Korelasi

Berdasarkan heatmap korelasi sebagian besar variabel nya memiliki hubungan yang positif. Pada korelasi Jalan kabupaten atau kota baik dengan Jalan kabupaten atau kota sedang bernilai 0,93 menunjukkan hubungan kuat. Beberapa juga menunjukkan korelasi negatif pada Jalan negara rusak berat dan Jalan kabupaten atau kota baik bernilai -0,31 menunjukkan hubungan berlawanan arah. Karena sudah memenuhi dapat lanjut analisis.

4.3 Standarisasi

Sebelum dilakukan PCA dan *K-Means*, seluruh variabel numerik distandarisasi menggunakan metode *Z-score*, Standarisasi ini penting karena data kondisi jalan memiliki rentang nilai yang sangat berbeda antar variabel.


Tabel 4. Hasil *Standarisasi Z-score*

Jalan negara baik	Jalan negara sedang	...	Krikil provinsi	Krikil kabupaten/kota
0.755614	1.483848	...	-0.214549	-0.335323
2.184271	1.596983	...	-0.260441	-0.099812
-1.280556	-0.997569	...	-0.903859	-0.614246

Berdasarkan Tabel 4, hasil *standarisasi Z-score* menunjukkan bahwa seluruh variabel telah dikonversi ke skala seragam dengan rata-rata nol dan *standar deviasi* satu. Nilai positif mengindikasikan kondisi di atas rata-rata nasional, sedangkan nilai negatif menunjukkan sebaliknya. Proses ini memastikan tidak ada variabel yang mendominasi perhitungan akibat perbedaan skala, sehingga analisis PCA dan *K-Means* dapat dilakukan secara objektif.

4.4 PCA (*Principal Component Analysis*)

Penentuan jumlah komponen utama dilakukan menggunakan *scree plot*. Hasil visualisasi nilai eigen setiap komponen ditunjukkan pada gambar berikut.

**Gambar 3.** *Scree Plot* PCA

Berdasarkan *scree plot* dan kriteria *Kaiser* (*eigenvalue* > 1), diperoleh lima komponen utama yang dipertahankan. Penurunan nilai eigen yang cukup tajam pada komponen awal menunjukkan bahwa sebagian besar variasi data telah direpresentasikan oleh kelima komponen tersebut. Hasil PCA ini selanjutnya digunakan sebagai representasi data pada tahap analisis berikutnya. Berikut hasil dari analisis PCA.

Tabel 5. Matriks PCA

	PC1	PC2	PC3	PC4	PC5
0	2.5777	0.2407	-1.771	-0.2157	0.2486
1	6.4857	0.8521	-1.4927	0.1640	-0.1898
...	...	...	...	...	...
37	2.4162	3.6607	1.1922	-0.0476	0.6877

Tabel 5 menunjukkan hasil transformasi data ke dalam lima komponen utama yang dipilih. Perbedaan nilai skor pada setiap komponen menunjukkan bahwa masing-masing observasi memiliki karakteristik yang berbeda dalam ruang komponen utama.

4.5 Loading Matriks dan Pembentukan Dimensi

Setelah jumlah komponen utama ditetapkan melalui nilai eigen yang hasilnya 5 selanjutnya dilakukan *loading matriks* untuk mengidentifikasi kontribusi setiap variabel terhadap komponen utama.


Tabel 6. Nilai *loading matriks*

Komponen Utama	Variabel	Nilai	Interpretasi
PC1	Jalan provinsi sedang, Jalan negara sedang, Jalan kabupaten/kota baik	0.889;0.859;0.851	Karakteristik umum infrastruktur jalan,
PC2	Jalan provinsi rusak berat, Krikil provinsi, Jalan negara rusak berat	0.864;0.761;0.751	Kondisi infrastruktur jalan rusak berat
PC3	Tidak aspal negara, Krikil kabupaten/kota, Jalan kabupaten/kota rusak berat	0.729; -0.434;-0.402	Karakteristik permukaan infrastruktur jalan
PC4	Jalan provinsi baik, Jalan negara rusak, Krikil provinsi	0.603;-0.391;0.380	Variasi infrastruktur jalan provinsi
PC5	Jalan provinsi baik, Jalan kabupaten/kota rusak, Krikil provinsi	0.603;-0.442;-0.389	Variasi infrastruktur jalan anatarwilayah.

Dari tabel diatas PC1 didominasi oleh variabel jalan provinsi sedang, jalan negara sedang, dan jalan kabupaten/kota baik dengan memiliki nilai 0.889; 0.859; 0.851. Hal itu mempresentasikan kondisi umum infrastruktur jalan, hal tersebut diterapkan pada komponen utama lainnya dengan melihat variabel yang memiliki nilai *loading* terbesar. Jika terdapat nilai *loading* negatif seperti pada PC3 maka itu tetap dihitung kontribusi besar, karena hal tersebut hanya menunjukkan arah hubungan berlawanan.

4.6 K-Means Clustering

Penentuan jumlah kluster optimal dilakukan menggunakan metode *Elbow* dan *Silhouette Score*. Berikut hasil dari *Elbow*:



Gambar 4. Penentuan Kluster Optimal dengan *Elbow Method*

Hasil lengkungan *Elbow* menunjukkan nilai k optimal dari 2 hingga 4. Selanjutnya akan dilakukan evaluasi dengan *Silhouette Score* dan memilih nilai tertinggi. Berikut hasilnya:

Tabel 7. Hasil Evaluasi *K-Means* untuk Berbagai Nilai *k*

<i>k</i>	Silhouette Score
2	0.3632
3	0.3364
4	0.3660

Hasil evaluasi dari $k=2$ hingga 4 menunjukkan bahwa jumlah *cluster* dengan *Silhouette Score* tertinggi adalah $K=4$. Selanjutnya analisis akan menggunakan $K=4$ untuk model, dengan hasil pengelompokan provinsi Indonesia sebagai berikut.

Tabel 8. Hasil *Clustering* Wilayah Indonesia

<i>Cluster</i>	Jumlah	Wilayah
1	4	Riau, Papua Barat, Papua, Papua Pegunungan
2	12	Aceh, Sumatera Utara, Sumatera Barat, Sumatera Selatan, Lampung, DKI Jakarta, Nusa Tenggara Timur, Kalimantan Barat, Kalimantan Tengah, Kalimantan Timur, Sulawesi Tengah, Sulawesi Selatan
3	19	Jambi, Bengkulu, KEP Bangka Belitung, Kepulauan Riau, D.I. Yogyakarta, Banten, Bali, Nusa Tenggara Barat, Kalimantan Selatan, Kalimantan Utara, Sulawesi Utara, Maluku, Maluku Utara, Papua Barat Daya, Papua Selatan, Papua Tengah
4	3	Jawa Barat, Jawa Tengah, Jawa Timur

Berdasarkan hasil *cluster* tersebut didapatkan 4 kelompok provinsi dengan karakteristik yang berbeda. *Cluster* 3 terbanyak berjumlah 19 provinsi. Menunjukkan bahwa sebagian besar provinsi memiliki karakteristik yang sama. Pada *cluster* 1 memiliki jumlah anggota 4 yang jika dilihat daerah nya memiliki karakteristik yang berbeda dari provinsi lainnya. Pada *cluster* 4 juga memiliki jumlah yang paling sedikit yaitu 3 mengindikasikan memiliki karakteristik yang sangat mirip satu sama lainnya.



Gambar 5. Peta *Cluster* Provinsi Indonesia

Berdasarkan Tabel 8, hasil *K-Means* dengan $k=4$ menghasilkan empat klaster dengan distribusi yang beragam. Klaster 2 merupakan klaster terbesar dengan 19 provinsi, diikuti klaster 1 dengan 12 provinsi, sedangkan klaster 0 dan klaster 3 masing-masing beranggotakan 4 dan 3 provinsi. Sebaran geografis klaster tersebut divisualisasikan pada Gambar 2, di mana klaster 2 (merah) mendominasi wilayah Kalimantan dan sebagian besar Indonesia Timur, klaster 1 (biru tua) terkonsentrasi di wilayah Sumatera bagian utara, klaster 3 (biru tosca) mencakup provinsi-provinsi di Pulau Jawa, serta klaster 0

(merah muda) tersebar di wilayah Papua dan kepulauan timur. Pola sebaran ini mengindikasikan adanya kemiripan karakteristik kondisi jalan antarprovinsi yang berdekatan secara geografis.

4.7 Analisis Karakteristik Klaster

Berdasarkan hasil nilai *loading* pada masing-masing komponen maka dapat memberikan karakteristik untuk setiap klaster dengan melihat nilai rata-rata komponen dan mencari komponen paling dominan, berikut hasilnya.

Tabel 9. Rata-rata Skor Komponen Utama Setiap Klaster

<i>Cluster</i>	PC1	PC2	PC3	PC4	PC5	Karakteristik
1	-1.116	3.491	0.844	0.808	-0.733	Dominasi komponen kerusakan jalan dan permukaan jalan
2	2.122	0.425	-0.614	-0.013	0.643	Dominasi kondisi umum infrastruktur jalan
3	-1.686	-0.747	-0.232	-0.079	-0.202	Tidak memiliki komponen utama yang dominan karena seluruh skor komponen bernilai negatif.
4	3.675	-1.621	2.802	-0.526	-0.317	Dominasi karakteristik umum infrastruktur jalan dan permukaan jalan

Berdasarkan Tabel 9, karakteristik setiap klaster ditentukan berdasarkan rata-rata skor komponen utama (*centroid*) hasil PCA. Skor komponen yang bernilai positif menunjukkan bahwa karakteristik pada komponen tersebut berada di atas rata-rata (nilai tengah = 0), sedangkan skor negatif menunjukkan karakteristik yang berada di bawah rata-rata. Berdasarkan nilai tersebut, Klaster 1 dicirikan oleh dominasi dimensi kerusakan jalan dan karakteristik permukaan jalan karena memiliki skor positif yang relatif tinggi pada komponen terkait. Klaster 2 menunjukkan dominasi pada dimensi kondisi umum infrastruktur jalan dengan skor positif tertinggi pada PC1. Klaster 3 tidak memiliki komponen yang dominan karena seluruh skor komponennya bernilai negatif, yang menunjukkan bahwa seluruh karakteristik berada di bawah rata-rata. Sementara itu, Klaster 4 dicirikan oleh dominasi dimensi kondisi umum infrastruktur jalan dan permukaan jalan karena memiliki skor positif yang tinggi pada komponen-komponen tersebut.

4 KESIMPULAN

Penelitian ini berhasil melakukan segmentasi pembangunan infrastruktur transportasi darat pada 38 provinsi di Indonesia menggunakan metode *Principal Component Analysis (PCA)* dan *K-Means Clustering*. Hasil analisis menunjukkan bahwa data memenuhi syarat untuk dilakukan PCA dan berhasil direduksi menjadi lima komponen utama yang mewakili karakteristik infrastruktur jalan. Berdasarkan evaluasi menggunakan *Elbow Method* dan *Silhouette Score*, diperoleh jumlah klaster optimal sebanyak empat klaster. Hasil pengelompokan menunjukkan bahwa setiap klaster memiliki karakteristik yang berbeda, yaitu dominasi kondisi umum infrastruktur jalan, kerusakan jalan, serta karakteristik permukaan jalan. Dengan demikian, segmentasi yang dihasilkan mampu menggambarkan perbedaan kondisi infrastruktur transportasi darat antarprovinsi dan dapat menjadi dasar dalam penyusunan kebijakan pembangunan yang lebih tepat sasaran dan merata.

DAFTAR PUSTAKA

- [1] P. Widodo, N. Ariani, and Y. N. Supriadi, "PERAN PEMBANGUNAN INFRASTRUKTUR TERHADAP KETIMPANGAN PENDAPATAN DI KOTA DAN KABUPATEN PULAU JAWA," *Jurnal Akuntansi dan Pajak*, vol. 23, no. 1, pp. 255–259, Jun. 2022.
- [2] D. A. K. Putri, M. R. Khalfani, M. R. Radinka, and N. S. Nirwana, "TRANSFORMASI INFRASTRUKTUR TRANSPORTASI UNTUK MENINGKATKAN KONEKTIVITAS DAN PERTUMBUHAN EKONOMI YANG BERKELANJUTAN DI JAKARTA," *Integrative Perspectives of Social and Science Journal*, vol. 2, no. 03 Juli, pp. 4788–4799, Jul. 2025.
- [3] "AHY Ungkap Ketimpangan Kualitas Jalan di RI." Accessed: Jun. 11, 2026. [Online]. Available: <https://finance.detik.com/infrastruktur/d-7726871/ahy-ungkap-ketimpangan-kualitas-jalan-di-ri>
- [4] B. W. Otok, A. Suharsono, P. Purhadi, R. E. Standsyah, and H. A. Azies, "Partitional *Clustering* of Underdeveloped Area Infrastructure with Unsupervised Learning Approach: A Case Study in the Island of Java, Indonesia," *Journal of Regional and City Planning*, vol. 33, no. 2, pp. 177–196, Aug. 2022, doi: 10.5614/jpww.2022.33.2.3.
- [5] S. Nugraha, F. Helmiah, and A. K. Syahputra, "Analisis Pengelompokan Desa Berdasarkan Indikator Sosial Ekonomi Menggunakan Metode *K-Means* | Jurnal Algoritma," May 2026, Accessed: Jun. 11, 2026. [Online]. Available: <https://jurnal.itg.ac.id/index.php/algoritma/article/view/3378>
- [6] K. H. Izzuddin and A. W. Wijayanto, "Pemodelan *Clustering Ward, K-Means, Diana*, dan PAM dengan PCA untuk Karakterisasi Kemiskinan Indonesia Tahun 2021," *Komputika*, vol. 13, no. 1, pp. 41–53, Apr. 2024, doi: 10.34010/komputika.v13i1.10803.
- [7] R. Hutagalung and Nuramaliyah, "PENGELOMPOKAN KABUPATEN/KOTA DI SUMATERA UTARA BERDASARKAN INDIKATOR INFRASTRUKTUR DAN LAYANAN DASAR MENGGUNAKAN *PRINCIPAL COMPONENT ANALYSIS* DAN *K-MEANS CLUSTERING*," *Prosiding Seminar Nasional Sains dan Teknologi "SainTek"*, vol. 3, no. 1, pp. 547–560, Feb. 2026.
- [8] D. Bagaskoro, P. Penengah, M. Junaidi, and M. I. Afandi, "Optimalisasi Pemetaan UMKM di Wilayah DKI Jakarta Melalui *K-Means Clustering* dan PCA," *Nusantara of Engineering (NOE)*, vol. 8, no. 02, pp. 297–306, Oct. 2025, doi: 10.29407/noe.v8i02.25791.
- [9] S. Sipayung and P. M. Hasugian, "Integration Of *Pca And K-Means Clustering* For Staple Food Segmentation In Support Of National Food Policy," *Sinkron : jurnal dan penelitian teknik informatika*, vol. 9, no. 4, pp. 3175–3189, Oct. 2025, doi: 10.33395/sinkron.v9i4.15343.
- [10] R. Hutagalung and Nuramaliyah, "PENGELOMPOKAN KABUPATEN/KOTA DI SUMATERA UTARA BERDASARKAN INDIKATOR INFRASTRUKTUR DAN LAYANAN DASAR MENGGUNAKAN *PRINCIPAL COMPONENT ANALYSIS* DAN *K-MEANS CLUSTERING*," *Prosiding Seminar Nasional Sains dan Teknologi "SainTek"*, vol. 3, no. 1, pp. 547–560, Feb. 2026.
- [11] I. N. Simbolon, "PREDIKSI KUALITAS AIR SUNGAI DI JAKARTA MENGGUNAKAN KNN YANG DIOPTIMALISASI DENGAN PSO," *Jurnal Informatika dan Teknik Elektro Terapan*, vol. 12, no. 2, Apr. 2024, doi: 10.23960/jitet.v12i2.4191.
- [12] A. Habibi and S. W. Saputra, "Jumlah dan Tipe Data Mempengaruhi Akurasi Pendugaan Parameter Surplus Produksi," *Akuatiklestari*, vol. 6, pp. 92–98, Apr. 2023, doi: 10.31629/akuatiklestari.v6i.5037.
- [13] G. R. Wahyudi, R. Rahmadden, E. Dini, S. Adrianto, and R. Fadila, "Pengelompokan Kabupaten di Indonesia untuk Pemetaan Pendapatan Daerah Menggunakan Algoritma *K-Means: Clustering* of Regencies in Indonesia for Regional Revenue Mapping Using the *K-Means Algorithm*," *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, vol. 5, no. 3, pp. 1143–1151, Aug. 2025, doi: 10.57152/malcom.v5i3.2206.

- [14] N. D. Astuti, M. Hajaroh, Y. Prihatni, A. Setiawan, F. A. Setiawati, and H. Retnawati, "Comparison of KMO Results, Eigen Value, Reliability, and Standard Error of Measurement: Original & Rescaling Through Summated Rating Scaling," *JP3I (Jurnal Pengukuran Psikologi dan Pendidikan Indonesia)*, vol. 13, no. 2, pp. 200–218, Nov. 2024, doi: 10.15408/jp3i.v13i2.36684.
- [15] R. A. Khufi, J. V. Gunawan, E. Y. Nainggolan, M. Nasrudin, and T. Trimono, "ANALISIS JUMLAH TENAGA KESEHATAN DI JAWA TIMUR TAHUN 2022-2023 MENGGUNAKAN METODE RM MANOVA SATU ARAH," *Jurnal Riset Sistem Informasi*, vol. 2, no. 3, pp. 29–38, Jul. 2025, doi: 10.69714/2hhgzp35.
- [16] R. S. Tobing, O. H. Sigalingging, R. K. Sinaga, and R. A. Lubis, "Penerapan *Principal Component Analysis* (PCA) untuk Reduksi Dimensi dan Pemetaan Karakteristik Nutrisi pada Produk Makanan Kemasan di Indonesia," *Algoritma: Jurnal Matematika, Ilmu pengetahuan Alam, Kebumihan dan Angkasa*, vol. 4, no. 1, pp. 20–30, Jan. 2026, doi: 10.62383/algoritma.v4i1.891.
- [17] N. S. Yasmin, N. R. Putri, and S. P. Wulandari, "REDUKSI FAKTOR-FAKTOR YANG MEMENGARUHI PEMBANGUNAN MANUSIA MENGGUNAKAN *PRINCIPAL COMPONENT ANALYSIS*," *Scientica: Jurnal Ilmiah Sains dan Teknologi*, vol. 3, no. 2, pp. 377–385, Dec. 2024.
- [18] C. Lumbantoruan and D. A. Megawaty, "Penerapan Metode *K-Means Clustering* dan *Principal Component Analysis* (PCA) untuk Pengelompokan Provinsi di Indonesia Berdasarkan Indikator Pendidikan," *Journal of Artificial Intelligence and Technology Information (JAITI)*, vol. 4, no. 2, pp. 120–131, Jun. 2026, doi: 10.58602/jaiti.v4i2.256.
- [19] T. Apriliana and E. Widodo, "Analisis *Cluster* Hierarki untuk Pengelompokan Provinsi di Indonesia berdasarkan Jumlah Base Transceiver Station dan Kekuatan Sinyal," *KONSTELASI: Konvergensi Teknologi dan Sistem Informasi*, vol. 3, no. 2, pp. 286–296, Dec. 2023, doi: 10.24002/konstelasi.v3i2.7143.
- [20] R. Hutagalung, "PENGELOMPOKAN KABUPATEN/KOTA DI SUMATERA UTARA BERDASARKAN INDIKATOR INFRASTRUKTUR DAN LAYANAN DASAR MENGGUNAKAN *PRINCIPAL COMPONENT ANALYSIS* DAN *K-MEANS CLUSTERING*," vol. 3, no. 1, 2026.
- [21] K. J. P. A. Z. Setiyanto, A. Muhaimin, and K. M. Hindrayani, "Improved *K-Means Clustering* untuk Analisis Ketimpangan Pembangunan Kabupaten/Kota di Pulau Jawa," *Driving Innovation through Data, Technology, and Engineering Seminar*, vol. 1, no. 1, pp. 210–219, 2025.
- [22] R. Sudrajat, A. I. Hadiana, and M. Melina, "Evaluasi Kualitas Klaster Wilayah Rawan Bencana Menggunakan *K-Means* dengan Silhouette dan *Elbow* Method | Jurnal Algoritma," Dec. 2025, Accessed: Jun. 11, 2026. [Online]. Available: <https://jurnal.itg.ac.id/index.php/algoritma/article/view/2379>
- [23] P. K. Ritonga and M. S. Hasibuan, "Analisis Perbandingan Silhouette dengan *Elbow* pada Algoritma *K-Means* dan DBSCAN," vol. 9, 2025.
- [24] B. P. Statistik, "Statistik Transportasi Darat 2024." Accessed: Jun. 11, 2026. [Online]. Available: <https://www.bps.go.id/assets/publication/2025/12/01/ed7ff73d58fc0719ee3df145/statistik-transportasi-darat-2024.html>

Active Submissions

male female adalah - Penelusur: Meet - bzt-tpj-xhg

ppjp.ulm.ac.id/journals/index.php/ragam/author/saveSubmit/5



RAGAM

Journal of Statistics & Its Application



HOME ABOUT USER HOME SEARCH CURRENT ARCHIVES ANNOUNCEMENTS CONTACT

Home > User > Author > Submissions > Active Submissions

ACTIVE SUBMISSIONS

Submission complete. Thank you for your interest in publishing with RAGAM: Journal of Statistics & Its Application.

- Active Submissions

RAGAM: Journal of Statistics and Its Application
 Program Studi Statistika, Fakultas MIPA, Universitas Lambung Mangkurat
 Jalan A. Yani Km.36, Kampus ULM Banjarbaru, Kalimantan Selatan, Indonesia 70714
 e-mail: ragam.statistika@ulm.ac.id
 website: https://ppjp.ulm.ac.id/journals/index.php/ragam

CC BY-SA

RAGAM: Journal of Statistics and Its Application
 ShareAlike 4.0 International License.

meet.google.com is sharing a window. Stop sharing Hide

Google Scholar

meet.google.com

Deal! Anda, me...

Active Submissions

male female adalah - Penelusur: meet.google.com/bzt-tpj-xhg

ppjp.ulm.ac.id/journals/index.php/ragam/author/index



RAGAM

Journal of Statistics & Its Application



HOME ABOUT USER HOME SEARCH CURRENT ARCHIVES ANNOUNCEMENTS CONTACT

Home > User > Author > Active Submissions

ACTIVE SUBMISSIONS

ACTIVE ARCHIVE

ID	MM-DD SUBMIT	SEC	AUTHORS	TITLE	STATUS
19564	06-18	ART	Noftasari	SEGMENTASI PEMBANGUNAN INFRASTRUKTUR TRANSPORTASI DARAT...	Awaiting assignment

1 - 1 of 1 Items

START A NEW SUBMISSION
 CLICK HERE to go to step one of the five-step submission process.

REFBACKS

ALL NEW PUBLISHED CONCURED

DATE ADDED	HITS	URL	ARTICLE	TITLE	STATUS	ACTION
There are currently no refbacks.						

Publish Ignore Delete Select All

Google Scholar